

# Bizonytalanságkezelés

# Bizonytalanság forrásai

- Hiányzó adat mellett történő következtetés

- Mi lehet a páciens betegsége?

- Bizonytalan adatra épülő következtetés

objektív

Pontatlan műszerek pontatlan leolvasása:  $80\text{ °C} \pm 2\text{ °C}$

szubjektív

- Következmény bizonytalansága:

- Mennyi az esélye, hogy egy sárga bőrű páciens hepatitiszes, ha ismerjük a *sárga bőrű hepatitiszesek / sárga bőrű betegek* arányát?

- Elmosódott jelentésű állítások:

- A nadrág erősen szennyezett

szubjektív

objektív

- Ellentmondó adatokból vagy ellentmondó következtetésekből származtatott következmény

# *Bizonytalanságkezelés alapkérdései*

- ❑ Hogyan **reprezentáljuk** a bizonytalanságot?
  - Az ismeretekhez numerikus vagy szimbolikus értéket rendelünk
- ❑ Hogyan **kombináljuk** a bizonytalanságot?
  - A logikai műveletek mentén komponált összetett ismeret bizonytalanságát a komponensek bizonytalanságából számoljuk.
- ❑ Hogyan **következtessünk** bizonytalan információból?
  - Mennyire (milyen mértékben) bizonytalan az a következmény, amelyre bizonytalan ismeretekből indulva bizonytalan következtetési szabállyal következtetünk?

# *1. Klasszikus valószínűség számítás*

- ❑ A központi kérdés az, hogy egy bizonytalan  $B \rightarrow A$  szabály alapján milyen bizonyossággal állítható az, hogy ha  $B$  igaz, akkor  $A$  is?
- ❑ Ugyanez másképpen is megfogalmazható: mi az  $A$  esemény bekövetkezésének valószínűsége, amikor a  $B$  esemény bekövetkezik.

Feltételes valószínűség:

$$p(A \mid B) = \frac{p(A \wedge B)}{p(B)} \quad \text{ha } p(B) > 0$$

# *Állítás = esemény*

- A továbbiakban az állítások mindig egy esemény bekövetkezéséről szólnak majd, így azokat (diszkrét) valószínűségi változók segítségével fogalmazhatjuk meg.

- $X_i = x_i$  esemény esetén  
 $X_i$  a diszkrét valószínűségi változó,  
 $x_i$  a változó értéke.

- Speciális jelölés:

- Amikor az  $X_i$  értéke csak *igaz* vagy *hamis* lehet, akkor használjuk

$X_i = igaz$  helyett  $X_i$ ,

$X_i = hamis$  helyett  $\neg X_i$

# Megjegyzés

- ❑ Egy adott problémakör (eseményrendszer) összes feltételes valószínűségét az események együttes valószínűségi eloszlásának ismeretében könnyen kiszámolhatjuk.
- ❑ De a gyakorlatban az együttes valószínűségi eloszlás
  - többnyire nem ismert explicit módon
  - túl sok apriori adat tárolását igényelné (a memória igény exponenciálisan nő az elemi események számával növelésével)
- ❑ Ezért egy feltételes valószínűség közvetlen kiszámolásához különféle elkerülő technikákat alkalmazunk.

# *Bayes tétel különféle alakjai*

a) **Klasszikus**

$$p(B | A) = \frac{p(A | B) \cdot p(B)}{p(A)}$$

b) **Háttértudás ( $E$ ) mellett**

$$p(B | A, E) = \frac{p(A | B, E) \cdot p(B | E)}{p(A | E)}$$

c) **Általánosított** (  $B_1, \dots, B_n$  teljes és független)

$$p(B_i | A) = \frac{p(A | B_i) \cdot p(B_i)}{\sum_k p(A | B_k) \cdot p(B_k)}$$

# *Szuvas-e egy fog, ha lyukas és fáj?*

*Russel-Norvig: AI*

□  $p(\textit{szuvas} \mid \textit{lyukas}, \textit{fáj}) = ?$

apriori ismeretek:

- $p(\textit{szuvas}) = 0.65$
- $p(\textit{fáj} \mid \textit{szuvas}) = 0.5$
- $p(\textit{fáj} \mid \neg \textit{szuvas}) = 0.1$
- $p(\textit{lyukas} \mid \textit{szuvas}) = 0.95$
- $p(\textit{lyukas} \mid \neg \textit{szuvas}) = 0.01$



$$p(\text{szuvas} \mid \text{lyukas}, \text{fáj}) = ?$$

## *Példa folytatása (Bayes tételek alkalmazása)*

- Ha a **klasszikus Bayes tételt** alkalmazzuk, akkor hamar elakadunk, mert csak a  $p(\text{sz})$ -t ismerjük.

$$p(\text{sz} \mid \text{ly}, f) = \frac{p(f, \text{ly} \mid \text{sz}) \cdot p(\text{sz})}{p(f, \text{ly})}$$

- Keressünk más utat! (**Bayes-i frissítés módszere**)
  - Először a **háttér tudás melletti Bayes tételt** alkalmazzuk a *fáj* eseményre, mint háttértényre,
  - És az ehhez szükséges  $p(\text{sz} \mid f)$ -re a **közönséges Bayes tételt** írjuk fel.

$$p(\text{sz} \mid \text{ly}, f) = \frac{p(\text{ly} \mid \text{sz}, f) \cdot p(\text{sz} \mid f)}{p(\text{ly} \mid f)} = \frac{p(\text{ly} \mid f, \text{sz}) \cdot p(f \mid \text{sz}) \cdot p(\text{sz})}{p(\text{ly} \mid f) \cdot p(f)}$$

# *Feltételes függetlenség*


- Közöséges függetlenség:  $p(A,B) = p(A) \cdot p(B)$
- Az  $A$  és a  $B$  események feltételesen függetlenek az  $E$  eseményre nézve (nincs közöttük közvetlen függőségi kapcsolat, csak az  $E$ -n keresztül), ha

$$p(A,B \mid E) = p(A \mid E) \cdot p(B \mid E)$$


- Az  $A$  és a  $B$  feltételesen függetlenek az  $E$ -re nézve, akkor  $p(A \mid B,E) = p(A \mid E)$  illetve  $p(B \mid A,E) = p(B \mid E)$

# *Feltételes függetlenség esetei*


- Az  $A$  és a  $B$  feltételesen függetlenek az  $E$ -re nézve:
  - $A$  is,  $B$  is függ az  $E$ -től, de más kapcsolat nincs köztük



- $A$ -tól függ az  $E$ , és  $E$ -től függ a  $B$ , de más kapcsolat nincs köztük




- $B$ -től függ az  $E$ , és  $E$ -től függ a  $A$ , de más kapcsolat nincs köztük



$$p(\text{szuvas} \mid \text{lyukas}, \text{fáj}) = ?$$

## *Példa folytatása (feltételes függetlenség kihasználása)*

- A lyukas fogat és a fogfájást a szuvasodás kapcsolja össze, mindkettő következménye a szuvasodásnak, ettől eltekintve függetlenek: Az *ly* **feltételesen független** az *f*-től az *sz*-re nézve, azaz  $p(\text{ly} \mid f, \text{sz}) = p(\text{ly} \mid \text{sz})$



- Hozzáolvasva ezt az eddigiekhez:

$$p(\text{sz} \mid \text{ly}, f) = \frac{p(\text{ly} \mid \text{sz}) \cdot p(f \mid \text{sz}) \cdot p(\text{sz})}{p(\text{ly} \mid f) \cdot p(f)}$$

- Már csak a nevezőbeli valószínűségeket nem ismerjük. Az apriori tudásunk alapján a számlálóbeli valószínűségeket akkor is ismernénk, ha ott az *sz* helyére  $\neg \text{sz}$ -t írnánk. Ilyenkor alkalmazhatjuk a **normalizálás** technikáját.

# Normalizálás

- Amikor egy eseménynek és az ellentetjének a valószínűségét ugyanazon, de ismeretlen együtthatóval számoljuk ki más valószínűségekből:

$$- \quad p(A) = \alpha \cdot u \quad \text{és} \quad p(\neg A) = \alpha \cdot v$$

- akkor az együttható könnyen meghatározható:

$$1 = p(A) + p(\neg A) = \alpha \cdot [u + v]$$

$$\alpha = 1 / [u + v]$$

$$p(\text{szuvas} \mid \text{lyukas}, \text{fáj}) = ?$$

## *Példa folytatása (normalizálás)*

□ ugyanaz  $\text{sz}$ -re és  $\neg\text{sz}$ -re:

$$p(\text{sz} \mid \text{ly}, \text{f}) = \frac{p(\text{ly} \mid \text{sz}) \cdot p(\text{f} \mid \text{sz}) \cdot p(\text{sz})}{p(\text{ly} \mid \text{f}) \cdot p(\text{f})} = \alpha \cdot p(\text{ly} \mid \text{sz}) \cdot p(\text{f} \mid \text{sz}) \cdot p(\text{sz})$$

$$p(\neg\text{sz} \mid \text{ly}, \text{f}) = \frac{p(\text{ly} \mid \neg\text{sz}) \cdot p(\text{f} \mid \neg\text{sz}) \cdot p(\neg\text{sz})}{p(\text{ly} \mid \text{f}) \cdot p(\text{f})} = \alpha \cdot p(\text{ly} \mid \neg\text{sz}) \cdot p(\text{f} \mid \neg\text{sz}) \cdot p(\neg\text{sz})$$

□ összeg:

$$1 = \alpha \cdot [p(\text{ly} \mid \text{sz}) \cdot p(\text{f} \mid \text{sz}) \cdot p(\text{sz}) + p(\text{ly} \mid \neg\text{sz}) \cdot p(\text{f} \mid \neg\text{sz}) \cdot p(\neg\text{sz})]$$

□ együttható:

$$\alpha = 1 / [p(\text{ly} \mid \text{sz}) \cdot p(\text{f} \mid \text{sz}) \cdot p(\text{sz}) + p(\text{ly} \mid \neg\text{sz}) \cdot p(\text{f} \mid \neg\text{sz}) \cdot p(\neg\text{sz})]$$

$$p(\text{szuvas} \mid \text{lyukas}, \text{fáj}) = ?$$

## *Példa befejezése*

apriori ismeretek:

$$p(\text{ly} \mid \text{sz}) = 0.7$$

$$p(\text{ly} \mid \neg \text{sz}) = 0.01$$

$$p(f \mid \text{sz}) = 0.5$$

$$p(f \mid \neg \text{sz}) = 0.1$$

$$p(\text{sz}) = 0.65$$

Bayes-i frissítés és a feltételes függetlenség felhasználása miatt:

$$p(\text{sz} \mid \text{ly}, f) = \alpha \cdot p(\text{ly} \mid \text{sz}) \cdot p(f \mid \text{sz}) \cdot p(\text{sz}) = \alpha \cdot 0.7 \cdot 0.5 \cdot 0.65$$

normalizálás:

$$\begin{aligned} \alpha &= 1 / [p(\text{ly} \mid \text{sz}) \cdot p(f \mid \text{sz}) \cdot p(\text{sz}) + p(\text{ly} \mid \neg \text{sz}) \cdot p(f \mid \neg \text{sz}) \cdot p(\neg \text{sz})] \\ &= 1 / [0.7 \cdot 0.5 \cdot 0.65 + 0.01 \cdot 0.1 \cdot 0.35] = 4.38885 \end{aligned}$$

eredmény:

$$p(\text{sz} \mid \text{ly}, f) = 4.38885 \cdot 0.2275 = 0.99846$$

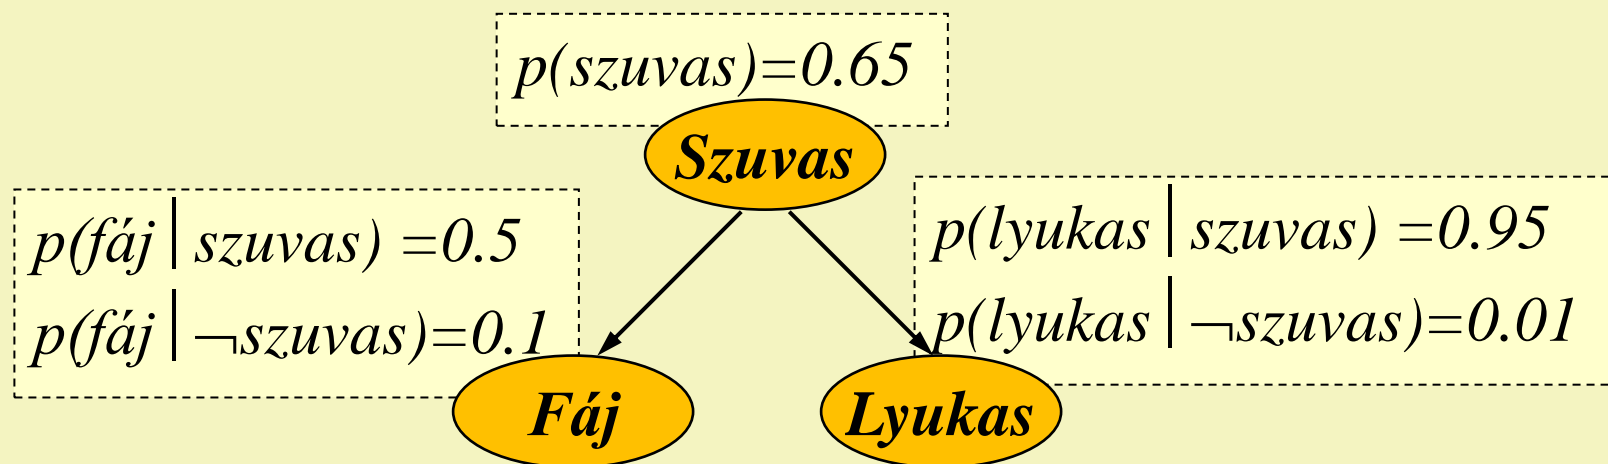
# *Bayes modell értékelése*

- ❑ Az apriori valószínűségekhez nehéz hozzájutni.
- ❑ Még a bevetett trükkök ellenére is sok apriori valószínűséget kell beszerezni és tárolni hozzá.
- ❑ A következtetés túl ötletszerűnek tűnik, nehéz algoritmizálni.
- ❑ Matematikailag jól megalapozott, de igen számításigényes, és magyarázatadásra nem alkalmas.
- ❑ A modell új ismeretekkel nehezen bővíthető. Nem elég ugyanis egy új esemény és a vele kapcsolatos feltételes események valószínűségeit megadni, ilyenkor a korábbi valószínűségi értékeket is felül kell bírálni.



## 2. Bayes (valószínűségi) hálók

- Az előző példa megoldásánál alkalmazott módszert általánosíthatnánk, ha a minimálisan szükséges apriori valószínűségeket úgy tárolnánk (**tömör reprezentáció**), hogy a **feltételes függetlenségek felismerése** egyértelmű és automatizálható legyen.




# *Reprezentáció Bayes hálóval*

- Tekintsük a tárgyprobléma valószínűségi változóit.
- Feleltessük meg a változókat egy **körmentes irányított gráf** csúcsainak.
- Ábrázoljuk az irányított élekkel a változók közötti közvetlen **ok-okozati összefüggéseket** (ez által implicit módon rögzítjük a feltételes függetlenségeket is).
- Adjuk meg az csúcsok **feltételes valószínűségi tábláit** (FVT):  
$$p(X_i=x_i \mid \text{szülő}(X_i)=x_{i1}, \dots, x_{ik})$$
  
ahol a  $\text{szülő}(X_i)$  az  $X_i$  változó csúcsának szülőcsúcsaihoz rendelt  $X_{i1}, \dots, X_{ik}$  változók együttesét jelöli.

# *Feltételes függetlenség felismerése Bayes hálóban*

- Legyenek  $A$ ,  $B$  és  $E$  összetett (több csúcs) események.
- Az  $A$  és  $B$  feltételesen független az  $E$ -re nézve, ha minden  $A$  és  $B$ -beli csúcs közti irányítatlan útvonalra az alábbi 4 eset valamelyike teljesül:



## Bayes háló kifejező ereje

- Az együttes valószínűségi eloszlás (a lánc-szabály alapján)

$$\begin{aligned} p(X_1=x_1, \dots, X_n=x_n) &= \\ &= p(X_n=x_n \mid X_1=x_1, \dots, X_{n-1}=x_{n-1}) \cdot p(X_1=x_1, \dots, X_{n-1}=x_{n-1}) = \\ &= \dots = \prod_{i=1 \dots n} p(X_i=x_i \mid X_1=x_1, \dots, X_{i-1}=x_{i-1}) \end{aligned}$$

- Sorszámozzuk meg úgy a változókat, hogy ha  $i > j$ , akkor  $X_i$ -ből ne vezessen irányított út  $X_j$ -be: ekkor  $\forall i: \text{szülő}(X_i) \subseteq \{X_1, \dots, X_{i-1}\}$ , és ekkor a feltételes függetlenség miatt

$$p(X_i=x_i \mid X_1=x_1, \dots, X_{i-1}=x_{i-1}) = p(X_i \mid \text{szülő}(X_i)=x_{i1}, \dots, x_{ik})$$

- Az adott tárgykör együttes valószínűségi eloszlása tehát a Bayes háló FVT-iből közvetlenül megkapható.

$$p(X_1=x_1, \dots, X_n=x_n) = \prod_{i=1 \dots n} p(X_i=x_i \mid \text{szülő}(X_i)=x_{i1}, \dots, x_{ik})$$

# *Bayes hálók tervezése*

- Határozzuk meg a tárgytartományt leíró változók halmazát, majd meghatározott sorrendben dolgozzuk fel őket:
  1. Válasszunk ki olyat, amely kizárólag a már háléhoz csatolt változóktól függ, és új csúcsként vegyük fel azt a hálóba
  2. A hálóbeli változóknak vegyük azt a minimális halmazát, amelyek közvetlenül hatnak az új változóra. Rajzoljuk be ezeket a függőségeket reprezentáló éleket.
  3. Töltsük ki az új csúcs FVT-jét.
  4. GOTO 1.

*A szomszédunk telefonált, hogy  
szól a betörés-riasztónk a lakásunkban.  
Betörtek volna hozzánk? Russel-Norvig: AI*

**Betörés**

$$p(B) = 0.001$$

**Riasztás**

$$p(R|B) = 0.95$$

$$p(R|\neg B) = 0.001$$

**Szomszéd**

$$p(Sz|R) = 0.9$$

$$p(Sz|\neg R) = 0.05$$

$$p(B|Sz) = p(Sz|B) \cdot p(B) / p(Sz)$$

Bayes tétel

$$= \alpha \cdot p(Sz|B) \cdot p(B)$$

normalizálás

$$= \alpha \cdot [p(Sz, R|B) + p(Sz, \neg R|B)] \cdot p(B)$$

telj fgl rsz

$$= \alpha \cdot [p(Sz|R, B) \cdot p(R|B) + p(Sz|\neg R, B) \cdot p(\neg R|B)] \cdot p(B)$$

lác szabály

$$= \alpha \cdot [p(Sz|R) \cdot p(R|B) + p(Sz|\neg R) \cdot p(\neg R|B)] \cdot p(B)$$

felt. fgl.

$$= \alpha \cdot 0.0008575$$

$$p(\neg B|Sz) = \alpha \cdot 0.0507991$$

$$\alpha = 19.3585$$

normalizálás vége

$$p(B|Sz) = 0.0166$$

## *Következtetés Bayes hálóokban*

- ❑ Célja egy feltételes valószínűség meghatározása a Bayes módszerre alapuló számítással (Bayes tételek, normalizálás, felbontás teljes fgl. eseményrendszerre, lánc-szabály, feltételes fgl.)
- ❑ Egy feltételes valószínűség kiszámolására egy (rekurzív) algoritmus készíthető, amelynek számításigénye erősen függ a háló bonyolultságától.
- ❑ Egyszeresen kötött hálókra (fa-gráfokra), ahol az irányítást figyelmen kívül hagyva két csúcs között nincsenek alternatív irányítatlan útvonalak, van lineáris futási idejű algoritmus.
- ❑ Többszörösen kötött hálók esetén különféle redukáló módszereket alkalmazhatunk.

*Példa kétszeresen kötött  
Bayes hálóra  
Russel-Norvig: AI*

|                |     |
|----------------|-----|
| $E\acute{E}=i$ | 0.5 |
| $E\acute{E}=h$ | 0.5 |

| $L=$           | $i$ | $h$ |
|----------------|-----|-----|
| $E\acute{E}=i$ | 0.0 | 1.0 |
| $E\acute{E}=h$ | 0.9 | 0.1 |

| $E=$           | $i$ | $h$ |
|----------------|-----|-----|
| $E\acute{E}=i$ | 0.8 | 0.2 |
| $E\acute{E}=h$ | 0.1 | 0.9 |

| $VP=$    | $i$  | $h$  |
|----------|------|------|
| $L+E=ii$ | 0.95 | 0.05 |
| $L+E=ih$ | 0.9  | 0.1  |
| $L+E=hi$ | 0.8  | 0.2  |
| $L+E=hh$ | 0.1  | 0.9  |



# *Következtetés többszörösen kötött hálókbán*

## □ Összevonásos eljárások

- Változók (csúcsok) összevonásával fa-gráfot kapunk, amelyben meg kell határozni az összevont csúcsok FVT-it.


## □ Vágóhalmaz feltételezésen alapuló eljárások

- Változók (csúcsok) elhagyásával annyi azonos szerkezetű fa-gráfot kapunk, ahányféleképpen az elhagyott változók értékét rögzíthetjük. Egy-egy fa-gráf súlya az a valószínűség, amely mellett az elhagyott változók a fa-gráfban rögzített értékeiket felveszik. A fa-gráfok FVT-it újra kell számolni. A válasz az egyes (esetleg csak a valószínűbb) fa-gráfokból kiszámolt eredmények súlyozott átlaga lesz.

## □ Sztochasztikus szimulációs eljárások

- A háló valószínűségi értékekeit figyelembe véve **példákat generálunk**. A válasz a jó példának az összes példához vett relatív gyakorisága.

# a) Összevonás



|                |     |
|----------------|-----|
| $E\acute{E}=i$ | 0.5 |
| $E\acute{E}=h$ | 0.5 |

**Esős évszak**

| $L=$           | $i$ | $h$ |
|----------------|-----|-----|
| $E\acute{E}=i$ | 0.0 | 1.0 |
| $E\acute{E}=h$ | 0.9 | 0.1 |

| $L+E=$         | $ii$ | $ih$ | $hi$ | $hh$ |
|----------------|------|------|------|------|
| $E\acute{E}=i$ | 0    | 0    | 0.8  | 0.2  |
| $E\acute{E}=h$ | 0.09 | 0.81 | 0.01 | 0.09 |

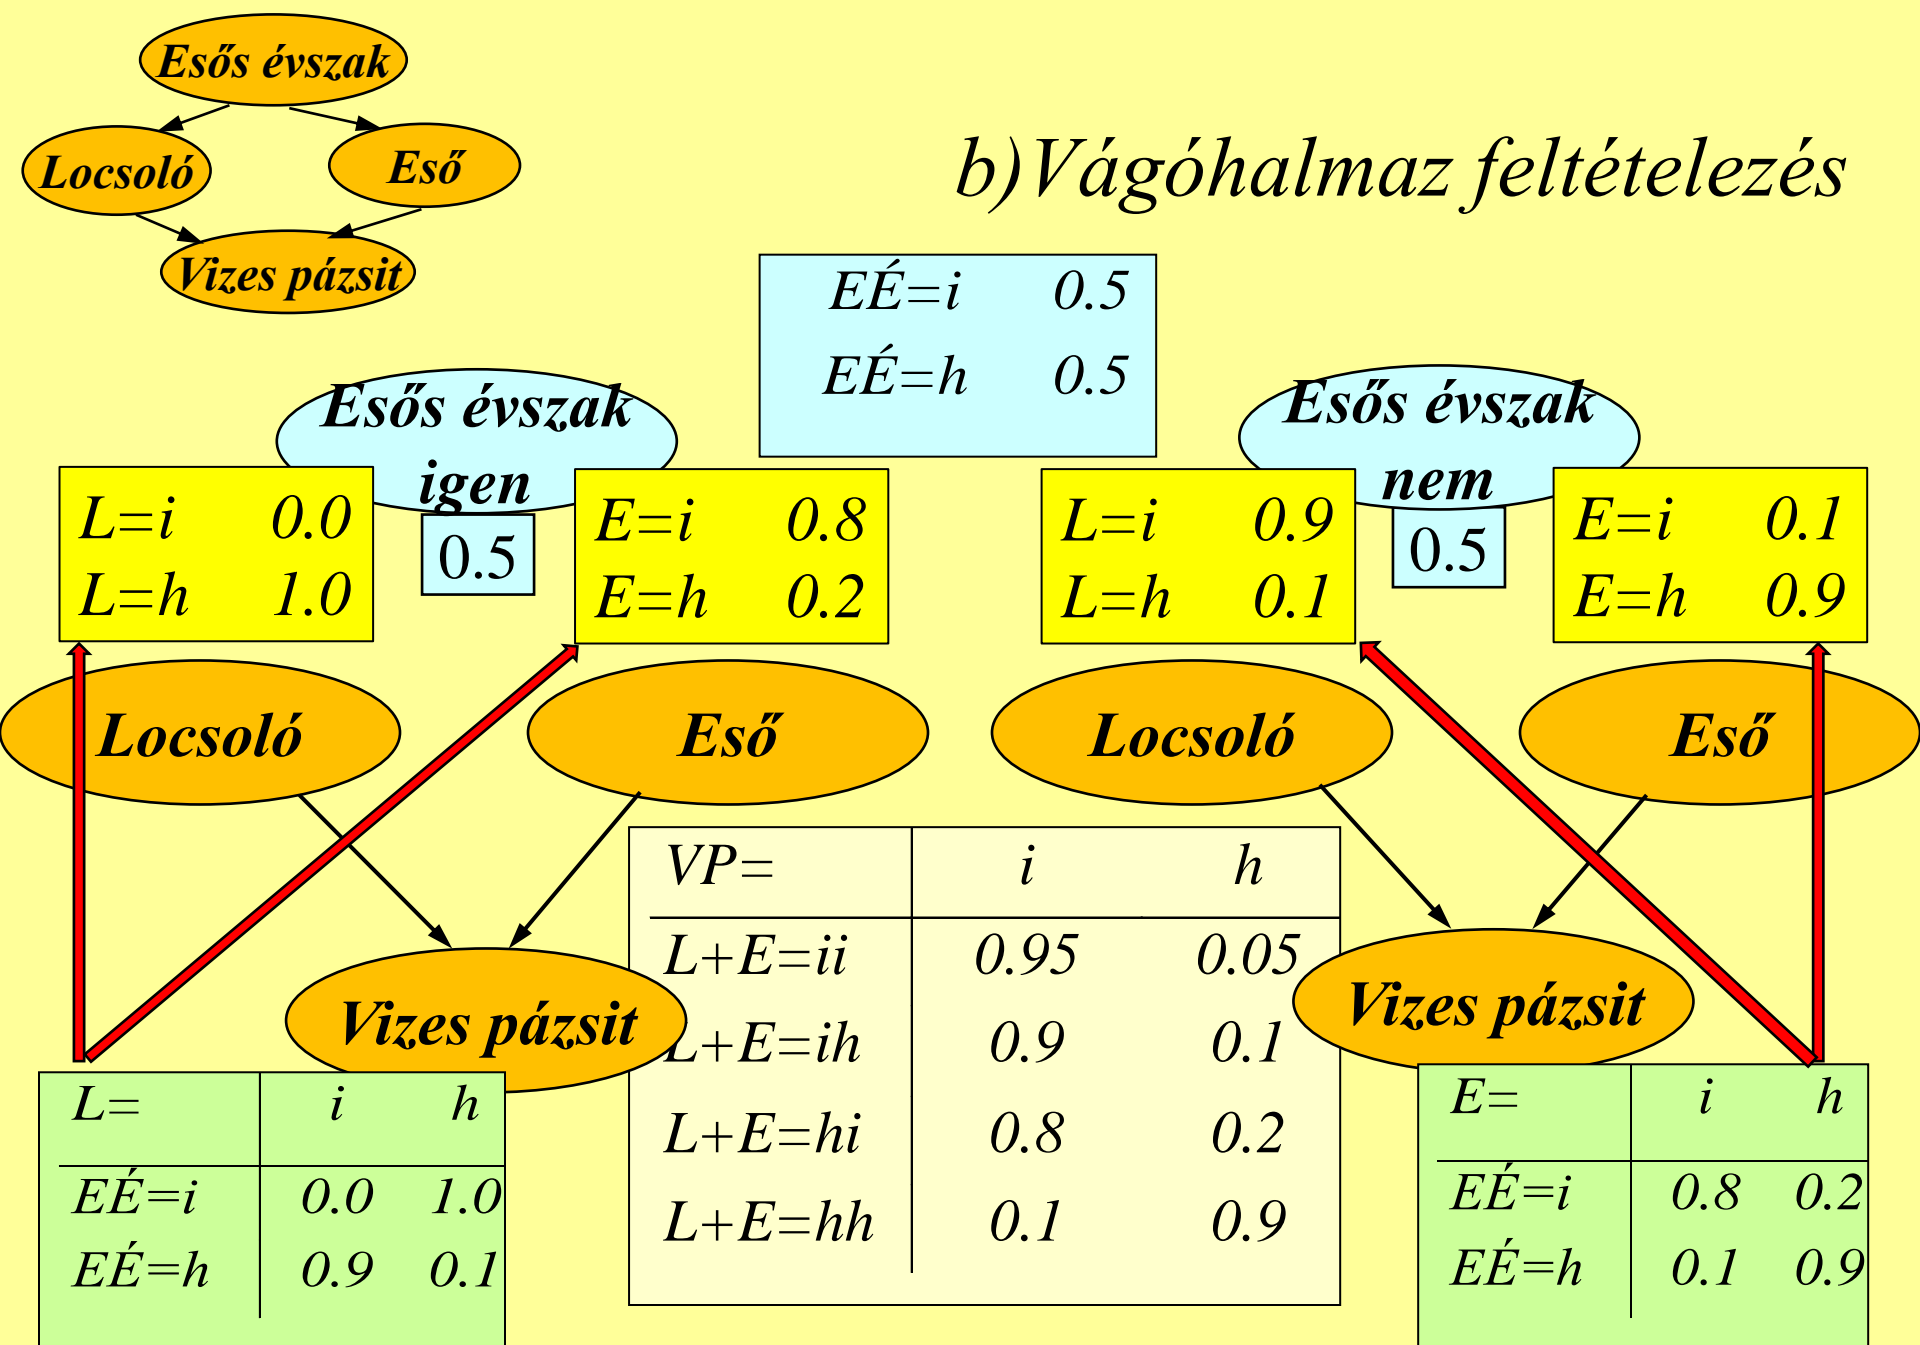
**Locsoló+Eső**

| $E=$           | $i$ | $h$ |
|----------------|-----|-----|
| $E\acute{E}=i$ | 0.8 | 0.2 |
| $E\acute{E}=h$ | 0.1 | 0.9 |

| $VP=$    | $i$  | $h$  |
|----------|------|------|
| $L+E=ii$ | 0.95 | 0.05 |
| $L+E=ih$ | 0.9  | 0.1  |
| $L+E=hi$ | 0.8  | 0.2  |
| $L+E=hh$ | 0.1  | 0.9  |

**Vizes pázsit**

## b) Vágóhalmaz feltételezés




# *Adott pontosságú vágóhalmaz feltételezés*

- ❑ Nem szükséges az összes fa-gráfra kiszámolni a keresett feltételes valószínűséget.
- ❑ Sokszor elég csak a legvalószínűbb hálókra súlyozott átlagot számolni, mert már ez is jól közelítheti a pontos választ.
  - A számolási hiba a ki nem értékelt hálók valószínűségeinek összege.

## c) Sztochasztikus szimuláció

$$p(A \mid B) = \frac{p(A,B)}{p(B)} = \frac{\text{Jó hasznos példák száma}}{\text{Összes hasznos példa száma}}$$

- A példa hasznos, ha a feltételt ( $B$ ) teljesíti
- Annak érdekében, hogy csak hasznos példát generáljunk, a feltételt ( $B$ ) alkotó tényváltozók értékét rögzítjük, de az így generált példát azzal a valószínűséggel súlyozzuk, amely mellett ezek a tényváltozók a számukra kijelölt értékeket felveszik. A relatív gyakoriságot a példák így súlyozott darabszáma alapján számítjuk.



## Egy hasznos példa előállítására a $p(\text{Vizes pázsit} \mid \text{Eső})$ számára

- ❑  $E\bar{E} = \text{Random}(0.5)$  mert  $p(E\bar{E}) = 0.5$ 
  - TF:  $E\bar{E} = \text{hamis}$ .
- ❑  $L = \text{Random}(0.9)$  mert  $p(L \mid \neg E\bar{E}) = 0.9$ 
  - TF:  $L = \text{igaz}$ .
- ❑  $E$  tényváltozó, értéke igaz, és  $p(E \mid \neg E\bar{E}) = 0.2$ 
  - Ezért  $E = \text{igaz} (0.2)$ 

Ez garantálja a példa hasznosságát

Ez a példa súlya
- ❑  $VP = \text{Random}(0.95)$  mert  $p(VP \mid E, L) = 0.95$ 
  - TF:  $VP = \text{igaz}$ . 

Ez tehát egy jó hasznos példa

# *Bayes hálók tanulása*

- ❑ Adott háló-struktúrában az **FVT tanulása** példákból nyert relatív gyakorisági értékek számolásával valósítható meg.
  - Probléma: ha a példák hiányosak, azaz nem ismerjük, hogy egy példában bizonyos változó milyen értéket vesz fel.
- ❑ A **háló szerkezetének tanulása** során metrikát definiálunk a feladat és az azt leíró háló „távolságára” és ez alapján keressük a legjobban illeszkedő struktúrát.

# *Bayes hálók értékelése*

- ❑ Kevesebb a priori valószínűséget kell benne tárolni ahhoz képest, ha az együttes valószínűségi eloszlásfüggvényt akarnánk ábrázolni.
- ❑ Egyszerűen bővíthető anélkül, hogy eddigi valószínűségeket újra kellene gondolni.
- ❑ A következtetés felhasználható magyarázatadásra.
- ❑ Matematikailag jól megalapozott, de – az erőfeszítéseink ellenére is – igen számításigényes.



### 3. Heurisztikus technikák

□ „Betörés-riasztó-szomszéd” probléma:

- szabályok:

*ha a szomszéd hallani véli a riasztót **akkor** szól a riasztónk*

$$Sz \rightarrow R \ (0.9)$$

*ha szól a riasztónk **akkor** betörtek hozzánk*

$$R \rightarrow B \ (0.95)$$

- tény: *a szomszéd telefonál, hogy hallja a riasztót*

$$Sz$$

□ Betörtek-e hozzánk?

- $Sz, Sz \rightarrow R \Rightarrow R ; R, R \rightarrow B \Rightarrow B$
- Új következtetési elv:  $T(p), T \rightarrow K(q) \Rightarrow K(p \cdot q)$
- $Sz(1) \Rightarrow R(0.9) \Rightarrow B(0.855)$

# *Ismert heurisztikus technológiák*

- ❑ MYCIN bizonytalanság kezelési technikája
- ❑ Dempster-Shafer elmélet
- ❑ Fuzzy következtetés